

Strojové učenie pre generáciu grafov s daným stupňom a obvodom

Machine Learning for Generation of Graphs of Given Degree and Girth


Vladimír Jančár

Mgr. Ján Pastorek


23. 06. 2026

Univerzita Komenského v Bratislave

Grafové neurónové siete




Grafové neurónové siete




Každý vrchol má vektor

Grafové neurónové siete




Každý vrchol má vektor




Vektor zobrazíme ako farbu

Grafové neurónové siete




Každý vrchol má vektor




Znázorníme message-passing

Grafové neurónové siete



Susedné vrcholy pošlú svoje vektory, a použijeme agregčnú funkciu na výpočet nového vektora pre vrchol v

Grafové neurónové siete




Susedné vrcholy pošlú svoje vektory, a použijeme agregčnú funkciu na výpočet nového vektora pre vrchol v

$$\blacksquare v = (220, 100, 60), \quad \blacksquare n_1 = (60, 200, 80), \quad \blacksquare n_2 = (60, 80, 220), \quad \blacksquare n_3 = (200, 200, 60)$$


$$\text{nový } v = \text{priemer}(v, n_1, n_2, n_3) = \left(\frac{540}{4}, \frac{580}{4}, \frac{420}{4} \right) = (135, 145, 105) \blacksquare$$

Message passing (mean aggregation)




Vektory ako čísla

Message passing (mean aggregation)




Vektory ako čísla




Vektory ako farby


Message passing (mean aggregation)



začiatok




po 2 kolách




po 8 kolách

Message passing (sum aggregation)




Vektory ako čísla

Message passing (sum aggregation)




Vektory ako čísla




Vektory ako farby


Message passing (sum aggregation)



začiatok




po 2 kolách




po 8 kolách


Grafové neurónové siete



Regularita a Obvod




Graf je **k -regulárny**, ak každý jeho vrchol má práve **k** susedov



Obvod grafu **g** je veľkosť najkratšieho cyklu v grafe

(k,g)-grafy




Toto je (3,5)-graf

Toto je (3,5)-graf
lebo je 3-regulárny


Toto je (3,5)-graf
lebo je 3-regulárny

(k,g) -grafy




Toto je $(3,5)$ -graf
lebo je 3-regulárny
a jeho obvod je 5

(k,g) -grafy




Tento $(3,5)$ -graf je **klietka**,
lebo je najmenší možný $(3,5)$ -graf

(k,g) -grafy



Toto je $(3,5)$ -graf


(k,g) -grafy



Toto je (3,5)-graf

Ale **nie je** to klietka

Reinforcement learning



Agent mení graf akciami a dostáva odmenu/trest a z toho sa učí

Natrénovaný RL agent by zostrojil (3,4)-graf takto:

Natrénovaný RL agent by zostrojil (3,4)-graf takto:

Reinforcement learning



Akcje

pridaj (0,1)


pridaj (0,2)

pridaj (0,3)


pridaj (4,1)

pridaj (4,2)

Reinforcement learning



Reinforcement learning



Akcje

► **pridaj (0,2)**


pridaj (0,3)

pridaj (4,1)

pridaj (4,2)

odober (0,1)

Reinforcement learning



Akcje

► **pridaj (0,3)**


pridaj (4,1)

pridaj (4,2)

pridaj (4,3)

odober (0,2)

Reinforcement learning



Akcje

► **pridaj (4,1)**


pridaj (4,2)

pridaj (4,3)

pridaj (5,1)

odober (0,3)

Reinforcement learning



Akcje

► **pridaj (4,2)**


pridaj (4,3)

pridaj (5,1)

pridaj (5,2)

odober (4,1)

Reinforcement learning



Akcje

► **pridaj (4,3)**


pridaj (5,1)

pridaj (5,2)

pridaj (5,3)

odober (4,2)

Reinforcement learning



Akccie

► pridaj (5,1)


pridaj (5,2)

pridaj (5,3)

odober (4,3)

~~pridaj (1,2) × (trojuholník)~~

Reinforcement learning



Akccie

► **pridaj (5,2)**


pridaj (5,3)

odober (5,1)

~~pridaj (1,2) x (trojuholník)~~

~~pridaj (1,3) x (trojuholník)~~

Reinforcement learning



Akccie

► **pridaj (5,3)**

odober (5,2)

~~pridaj (1,2) x (trojuholník)~~

~~pridaj (1,3) x (trojuholník)~~



~~pridaj (2,3) x (trojuholník)~~

Reinforcement learning: výsledky

Výsledky z PERUN behu, dopĺňam.



RL sa podarilo zostrojiti len malé cieľe.

Voltage lifts



Zachová k -regularitu a zvětší graf



Voltage lifts



Zachová k -regularitu a zvětší graf

Potřebujeme zvolit základný graf G a grupu Γ

Voltage lifts





Zachová k -regularitu a zvětší graf

Potrebujeme zvolit základný graf G a grupu Γ

Priradiť jej prvky hranám - napätia

Voltage lifts



Zachová k -regularitu a zvětší graf


Potrebujeme zvolit základný graf G a grupu Γ

Priradiť jej prvky hranám - napätia

Výsledný počet vrcholov =

$$|\Gamma| \times |V(\text{grafu})|$$

Voltage lifts




Základný graf

Voltage lifts



Zvolená grupa: $Z_5 = \{0, 1, 2, 3, 4\}$

Voltage lifts




Voltage lifts




Pre každý prvok Z_5 jedna kópia vrcholu

Voltage lifts




Slučka na 0 dá hrany $(0,x) \rightarrow (0,x+1)$. Vznikne vonkajší päťuholník

Voltage lifts



Slučka na 1 dá hrany $(1,x) \rightarrow (1,x+2)$. Vznikne vnútorná hviezda


Voltage lifts




Hrana $0 \rightarrow 1$ dá hrany $(0,x) \rightarrow (1,x)$. Výsledek je Petersenov graf

Voltage lifts a GNN

GNN tu vieme použiť na
urýchlenie hľadania
vyhovujúceho priradenia
napätí




Voltage lifts a GNN



GNN tu vieme použiť na
urýchlenie hľadania
vyhovujúceho priradenia
napätí

GNN sme učili hádať obvod
po lifte podľa priradených
napätí

Voltage lifts a GNN




GNN tu vieme použiť na
urýchlenie hľadania
vyhovujúceho priradenia
napätí

GNN sme učili hádať obvod
po lifte podľa priradených
napätí



Výsledky dopĺňam z behu na
PERUN

Refinement





2-swap: zachováme stupeň, vymažeme krátky cyklus

Refinement




Prvý 2-swap: odoberieme dve hrany (vľavo), pridáme dve nové (vpravo)

Refinement



Druhý 2-swap: odoberieme (vľavo), pridáme (vpravo)

Refinement



Po dvoch swapoch má graf obvod 5

Refinement a GNN



GNN navrhuje poradie kandidátov


Refinement a GNN



GNN navrhuje poradie kandidátov



výsledky dopĺňam z behu na PERUN

Excision






Začneme s priveľkým (3,5)-
grafom: dodekaéder, 20
vrcholov

Excision







Z koreňa vyrastie BFS
strom do hĺbky 2 - Moorov
polomer

Excision








Strom naraz odstránime

Chýbajúce hrany zošijeme
tak, aby obvod ostal 5




Excision




Výsledek je Petersenov graf, teda (3,5)-klietka

Excision a GNN



GNN navrhuje ktoré hrany vytvoriť.

Excision a GNN



GNN navrhuje ktoré hrany vytvoriť.

výsledky dopĺňam z behu na PERUN

Forge

Producer
voltage · dosah

Refinement
oprava · platnosť

Excision
zmenši · veľkosť

Forge


Producer
voltage · dosah

Refinement
oprava · platnosť


Excision
zmenši · veľkosť

Odovzdanie cez **defective fraction** $\leq \tau$, producer je vymeniteľný.


Výsledky



Výsledky



Výsledky




voltage-rl: najširší dosah.

Klasické: najmenšie tam, kde fungujú.

Forge: úspech 0,46, veľkosť 1,23× Moore.

Výsledky



voltage-rl: najširší dosah.

Klasické: najmenšie tam, kde fungujú.

Forge: úspech 0,46, veľkosť 1,23× Moore.

Učené zriedka prekoná neučené, a to je zistenie.

Otázka školiteľa (1)

Čakal som, že kombinovaná metóda Forge dosiahne najlepšie výsledky. Podľa tabuliek vychádza najlepšie A* pri hľadaní najmenšieho príkladu (k,g)-grafu a voltage-RL pri hľadaní aspoň nejakého príkladu. Čo zapríčinilo dané výsledky?

Otázka školiteľa (2)

Prečo ste metódy zastavili po 60 sekundách? Ako vieme, či modely so strojovým učeníím nepotrebovali viac času na konvergenciu?

Otázka oponenta (1)

V práci ukazujete, že štandardné GNN nedokážu spoľahlivo predikovať obvod. Aké štrukturálne alebo pozičné príznaky by ste do modelu pridali, aby lepšie zachytil globálnu cyklickú štruktúru grafu?

Otázka oponenta (2)

Pipeline Forge kombinuje voltage producer, refinement a excision.
Ako by ste systematicky ladili prah defective fraction a ako by ste experimentálne odlišili prínos diverzity kandidátov od kvality naučenej politiky?

Záver

Postavil som postupnosť metód na generovanie (k,g) -grafov a porovnal učené verzie s neučenými.

Hlavné zistenie je, že učenie navádza hľadanie, ale nenahrádza exaktné overenie.

Ďalej by sa dali pridať pozičné a štruktúrne príznaky pre lepšiu predikciu obvodu.

Ďakujem za pozornosť.