

Strojové učenie pre generáciu grafov s daným stupňom a obvodom

Machine Learning for Generation of Graphs of Given Degree and Girth


Vladimír Jančár

Mgr. Ján Pastorek


23. 06. 2026

Univerzita Komenského v Bratislave


Grafové neurónové siete



Grafové neurónové siete




Každý vrchol má vektor




Zobrazme ako farby (podľa RGB)


Grafové neurónové siete



začiatok




po 2 kolách




po 8 kolách

Grafové neurónové siete




Po message-passingu nesie každý vrchol vektor svojho okolia, ktorý je vstupom do neurónovej siete

Regularita a Obvod




Graf je **k -regulárny**, ak každý jeho vrchol má práve **k** susedov




Obvod grafu **g** je veľkosť najkratšieho cyklu v grafe

(k,g)-grafy




Toto je (3,5)-graf

(k,g) -grafy




Toto je $(3,5)$ -graf
lebo je 3-regulárny

(k,g) -grafy




Toto je $(3,5)$ -graf
lebo je 3-regulárny
a jeho obvod je 5

(k,g) -grafy



Tento $(3,5)$ -graf ale **nie je** klietka

(k,g) -grafy




Toto je tiež $(3,5)$ -graf

a je to **klietka** - najmenší možný
 $(3,5)$ -graf


Moore's bound

Najmenší počet vrcholov, ktorý (k,g) -graf vôbec musí mať



Z koreňa: k susedov, potom každý ďalší $k-1$. Do hĺbky $(g-1)/2$ musia byť všetky rôzne, inak vznikne cyklus kratší ako g

Reinforcement learning




Agent stavia graf hranu po hrane, za to dostáva odmenu a z nej sa učí

Reinforcement learning


✓ **legálny ťah**

uzavrie 5-cyklus




✗ **porušený stupeň**

vrchol by mal stupeň $> k$



✗ **porušený obvod**

vznikol by 4-cyklus $< g$



Akcia je dvojica vrcholov (u, v) : ak hrana chýba, pridá sa, inak sa odoberie

Reinforcement learning

Cieľ: k -regulárny graf s obvodom aspoň g

Veľká odmena za hotový graf, priebežne malá odmena za každý vrchol, ktorý dosiahne stupeň k , a za pridávané hrany



Agent dostane pevný počet vrcholov a aktivuje ich hranami

Reinforcement learning: výsledky

Priame RL zvládlo len najmenšie ciele: (5,3), (3,5), (6,3) a podobné



Úspešnosť 8 %, a zo všetkých metód bolo najpomalšie

Voltage lifts



Zachová k -regularitu a zvětší graf



Voltage lifts



Zachová k -regularitu a zvětší graf

Potřebujeme zvolit základný graf G a grupu Γ

Voltage lifts





Zachová k -regularitu a zvětší graf

Potrebujeme zvolit základný graf G a grupu Γ

Priradiť jej prvky hranám - napätia

Voltage lifts



Zachová k -regularitu a zvětší graf


Potrebujeme zvolit základný graf G a grupu Γ

Priradiť jej prvky hranám - napätia

Výsledný počet vrcholov =

$$|\Gamma| \times |V(\text{grafu})|$$

Voltage lifts




Základný graf

Voltage lifts



Zvolená grupa: $Z_5 = \{0, 1, 2, 3, 4\}$

Voltage lifts




Voltage lifts




Pre každý prvok Z_5 jedna kópia vrcholu

Voltage lifts




Slučka na 0 dá hrany $(0,x) \rightarrow (0,x+1)$. Vznikne vonkajší päťuholník

Voltage lifts




Slučka na 1 dá hrany $(1,x) \rightarrow (1,x+2)$. Vznikne vnútorná hviezda

Voltage lifts



Hrana $0 \rightarrow 1$ dá hrany $(0,x) \rightarrow (1,x)$. Výsledok je Petersenov graf

Voltage lifts a GNN




Napätia hľadáme
prehľadávaním

GNN vie ohodnotiť
kandidátov a navádzať
hľadanie

Algebraické 63 %, s GNN
predikciou 59 %. GNN tu
nepomohlo.

Voltage lifts a GNN




RL politika prirad'uje napätia
po jednej hrane

Odmena = obvod grafu po
lifte



Najširší dosah zo všetkých
metód: 84 %

Refinement





2-swap: zachováme stupeň, vymažeme krátky cyklus

Refinement




Prvý 2-swap: odoberieme dve hrany (vľavo), pridáme dve nové (vpravo)

Refinement



Druhý 2-swap: odoberieme (vľavo), pridáme (vpravo)

Refinement



Po dvoch swapoch má graf obvod 5

Refinement a GNN



GNN navrhuje poradie kandidátov

Refinement a GNN




GNN navrhuje poradie kandidátov

Krok bol rýchlejší, no úspešnosť nižšia: 51 % oproti 75 % bez GNN

The image shows a presentation slide with a dark background. At the top left, the word "Excision" is written in a large, white, sans-serif font. Below the title, there is a grid of small, light-gray text consisting of the words "GRAPH", "NEURL", and "NTWRK" arranged in a repeating pattern across many rows and columns. Overlaid on the right side of the grid is a large, bold, white text box containing the sentence "Z veľkého (k,g)-grafu spravíme menší (k,g)-graf". In the bottom right corner, the page number "15 / 23" is displayed in a white font.



[illegible]

Excision






Začneme s priveľkým (3,5)-
grafom: dodekaéder, 20
vrcholov

Excision







Z koreňa vyrastie BFS
strom do hĺbky 2 - Moorov
polomer

Excision








Strom naraz odstránime

Chýbajúce hrany zošijeme
tak, aby obvod ostal 5




Excision




Výsledek je Petersenov graf, teda (3,5)-klietka

Excision a GNN



GNN navrhuje ktoré hrany vytvoriť.

Excision a GNN



GNN navrhuje ktoré hrany vytvoriť.

Bez excízie $2,06\times$ Moore, s ňou $1,51\times$. Naučené zošitie zatiaľ neukázalo zisk

Voltage lifts

- ✓ veľký dosah
- × grafy 2× Moore

Klasické hľadanie

- ✓ veľkosť kletky
- × úzky dosah


Refinement + Excision

- ✓ opraví a zmenší
- × samy nič nepostavia

Každá metóda je silná inde. Forge ich zreťazí, nech každá robí len to svoje.


Forge

Producer




lift, často skoro-dobrý

Refinement




obvod = g

Excision



zmenšený ku kletke

Forge




$$\text{defective fraction} = \frac{|E_{\text{def}}|}{|E|}$$


E_{def} = hrany ležiace na cykle kratšom ako g , teda tie, čo kazia obvod

Brána pustiť na opravu len lify s malým podielom chybných hrán

Výsledky




Výsledky



Otázka školiteľa (1)

Čakal som, že kombinovaná metóda Forge dosiahne najlepšie výsledky. Podľa tabuliek vychádza najlepšie A* pri hľadaní najmenšieho príkladu (k,g) -grafu a voltage-RL pri hľadaní aspoň nejakého príkladu. Čo zapríčinilo dané výsledky?

Otázka školiteľa (1)




A* je presné len na ľahkých cieľoch. Voltage-RL má dosah, no grafy okolo 2× Moore. Na **ťažkej hranici**, kde A* nič nevráti, je **Forge** najmenší platný graf (okolo 1,23× Moore). Nevyhráva stĺpec, lebo stĺpce sa vyhrávajú na ľahkých cieľoch.

Otázka školiteľa (2)

Prečo ste metódy zastavili po 60 sekundách? Ako vieme, či modely so strojovým učeníím nepotrebovali viac času na konvergenciu?

Otázka školiť (2)



Začal som na 5 minútach, no výsledok bol vždy rovnaký: čo sa podarí, podarí sa do minúty, inak ani za päť. Preto 1 minúta, **rovnaký rozsččet pre všetky metódy**. Učenie modelov je **offline pri tréningu**, nie počas hľadania.


Otázka oponenta (1)

V práci ukazujete, že štandardné GNN nedokážu spoľahlivo predikovať obvod. Aké štrukturálne alebo pozičné príznaky by ste do modelu pridali, aby lepšie zachytil globálnu cyklickú štruktúru grafu?


Otázka oponenta (1)

Obvod je globálny — lokálne videnie nestačí

Receptívne pole GNN ($L = 2$ vrstvy) vs. girth $g = 6$



Lokálne sa dá,
globálne nie



Problém je **reprezentačný**: MPNN nevie spočítať obvod (Garg, 2020), 1-WL nevidí dlhé cykly.



Riešením je pridať príznaky: **(1) RWSE**, **(2) počty cyklov (GSN)**, **(3) spektrálne kódovanie**. Naš model **Loopy** už ide týmto smerom.

Otázka oponenta (2)

Pipeline Forge kombinuje voltage producer, refinement a excision.
Ako by ste systematicky ladili prah defective fraction a ako by ste experimentálne odlišili prínos diverzity kandidátov od kvality naučenej politiky?

Otázka oponenta (2)

Prah τ a prínos učenia



Excízia: naučené zošitie = klasické (žiadny zisk)

Prah τ je kompromis výťažok/náklad, ladený sweepom cez validačné ciele (zvolené 0,2). Prínos **diverzity a politiky** oddelíme 2×2 abláciou. Doterajšie dáta: zisk je zo **šírky hľadania**, nie z naučenej politiky.

Záver

Postavil som postupnosť metód na generovanie (k,g) -grafov a porovnal učené verzie s neučenými.

Hlavné zistenie je, že učenie navádza hľadanie, ale nenahrádza exaktné overenie.

Ďalej by sa dali pridať pozičné a štruktúrne príznaky pre lepšiu predikciu obvodu.

Ďakujem za pozornosť.